Projeto de Bloco: Análise e Segurança de Agentes de IA

EduBot Analytics - TP3

Alunas: Maitê Mota Belo de Souza Silva e Patricia Dias Rodrigues

Professor: Ricardo Pires Mesquita

Data: 25/10/2026

Repositório: https://github.com/patricia-diasr/edubot-analytics

API publicada: https://edubot-analytics.onrender.com (documentação em /docs)

Sumário

1. Visão geral **3**

1.1 Organização do repositório 3

2. Regressão linear e transição para classificação **4**

2.1 Regressão linear múltipla 4

2.2 Limitações da regressão 5

2.3 Pergunta de classificação 5

2.4 Planejamento do T2 7

3. Suíte de testes de segurança **7**

4. Integração contínua com GitHub Actions **8**

5. Auditoria final de segurança **12**

5.1 Checklist OWASP API Security Top 10 13

5.2 Scan final com OWASP ZAP 13

6. Documentação OpenAPI (/docs) **15**

7. Deploy e prontidão para o pentest **17**

8. Planejamento do T2: pentest e segurança do agente **18**

8.1 Plano de escopo do pentest 18

8.2 Plano de segurança do agente 19

9. Atualização da modelagem de ameaças **19**

10. Uso de IA **21**

11. Índice de evidências **21**

1. Visão geral

O **EduBot Analytics** é um agente de IA de suporte acadêmico universitário. Ele atende alunos de graduação em pedidos de matrícula, trancamento de disciplinas e consulta de notas.

Desafio	Descrição
Domínio	Atendimento acadêmico: matrícula, trancamento, consulta de notas
Desafio de IA	Classificar a urgência do pedido e a sua categoria (burocrático ou pedagógico)
Desafio de segurança	Evitar que alunos manipulem o agente para alterar notas ou acessar registros de outros estudantes

O TP3 consolida a análise estatística e a API construída nos TPs anteriores. Na frente de Dados/IA, foi criada uma regressão linear múltipla, analisados os resíduos e formalizada a futura tarefa de classificação. Na frente de Infra/Sec, a API passou por uma auditoria final de segurança, ganhou uma suíte de testes integrada ao GitHub Actions, uma documentação OpenAPI completa e foi publicada em ambiente online, pronta para ser alvo do pentest do TP4.

1.1 Organização do repositório

Pasta	Conteúdo
`api/`	API FastAPI: código (`app/`), 67 testes de segurança (`tests/`), dependências e modelo do `.env`
`eda/`	Notebooks de EDA, dataset, figuras e documentação dos dados
`dfd/`	DFD (versão 3), análise CIA, modelagem de ameaças STRIDE e histórico de versões do DFD
`security/`	Auditoria final, findings e relatórios do OWASP ZAP, decisões técnicas, deploy, plano de pentest e evidências
`.github/workflows/`	Workflow do GitHub Actions com os testes de segurança
`entregas/`	Relatórios de cada TP (Markdown, script e PDF) e prints de evidência

As instruções de instalação, execução e testes estão no `README.md`, na raiz do repositório.

2. Regressão linear e transição para classificação

2.1 Regressão linear múltipla

O notebook `eda/eda_edubot_tp3.ipynb` usa regressão linear múltipla para prever `n_chars`, o número de caracteres de uma mensagem. As variáveis explicativas são `n_palavras`, as flags linguísticas do Bitext e `categoria_edubot`, transformada com one-hot encoding.

O pré-processamento e o `LinearRegression` ficam no mesmo pipeline do scikit-learn. Os dados foram separados em 80% para treino e 20% para teste, com `random_state=42`.

Medida	Resultado
Registros de treino	16.804
Registros de teste	4.202
R^2 no teste	0,690
RMSE	6,243 caracteres
Média dos resíduos	0,097

O modelo explica cerca de 69% da variação no número de caracteres. Isso acontece principalmente porque mensagens com mais palavras tendem a ter mais caracteres. O resultado não significa que o modelo entendeu o conteúdo.

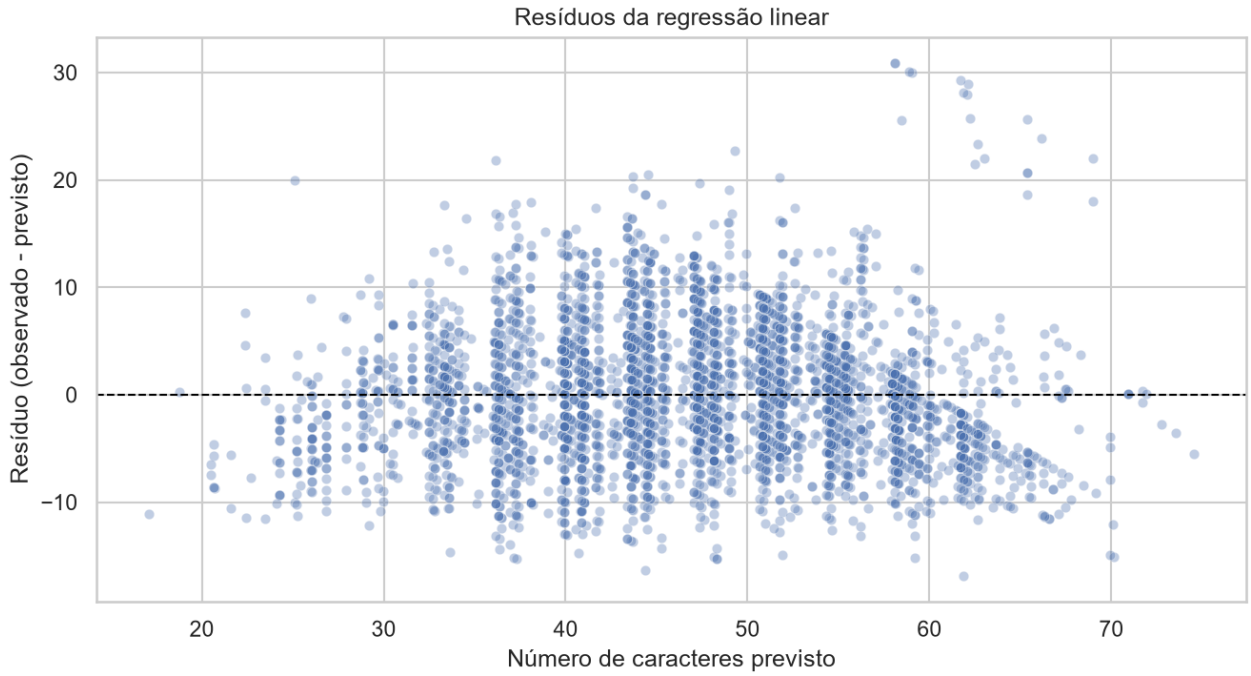


Figura 1 - Resíduos da regressão linear

Os resíduos ficam em torno de zero, mas a dispersão não é perfeitamente uniforme. As faixas diagonais aparecem porque caracteres e palavras são contagens inteiras. A hipótese de variância constante não é plenamente atendida.

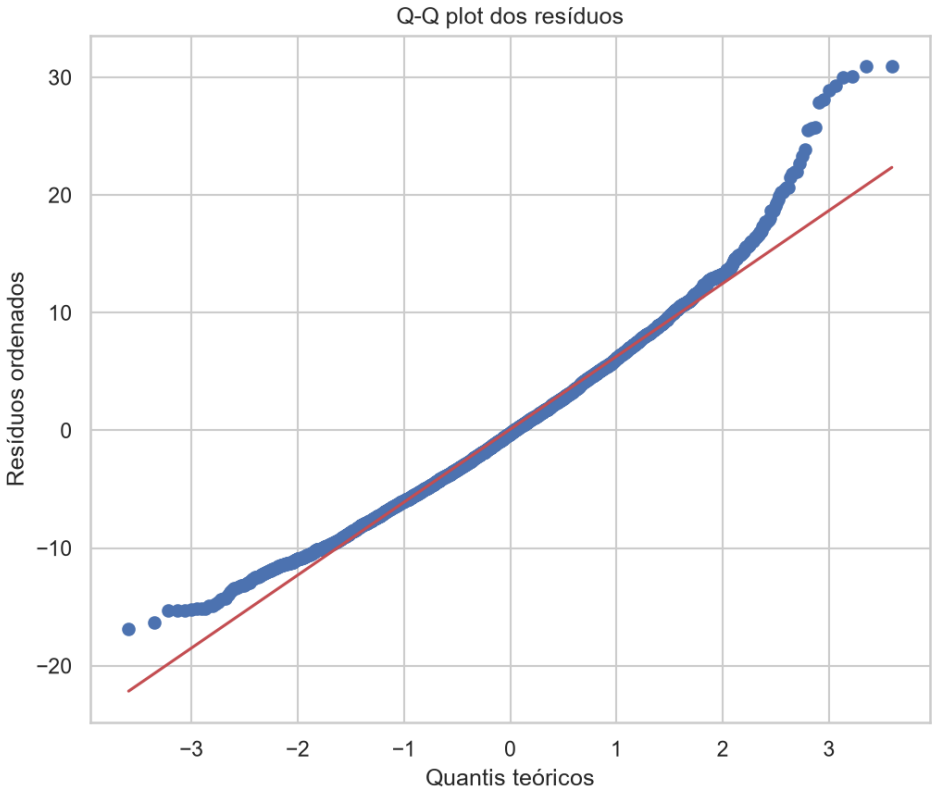


Figura 2 - Q-Q plot dos resíduos

O centro do Q-Q plot fica razoavelmente perto da reta, mas as caudas se afastam. Os resíduos não são perfeitamente normais.

2.2 Limitações da regressão

- O alvo `n_chars` foi escolhido para praticar regressão e não representa a intenção da pessoa.
- A relação entre palavras e caracteres é parcialmente mecânica.
- Os resíduos apresentam desvios de homocedasticidade e normalidade.
- O Bitext é sintético, em inglês e voltado a e-commerce.
- Intenções são classes sem ordem numérica. A regressão linear pode devolver valores contínuos sem significado e não resolve a tarefa final.

2.3 Pergunta de classificação

A pergunta formalizada para o T2 é:

> Dado o texto de uma mensagem de atendimento, qual é a intenção do usuário?

A entrada será `instruction` e a saída será uma das 23 classes de `intent_edubot`. O dataset tratado tem 21.006 mensagens. A maior parte das classes tem entre 700 e 1.000 exemplos. `disciplina_trancar` é a menor, com 493.

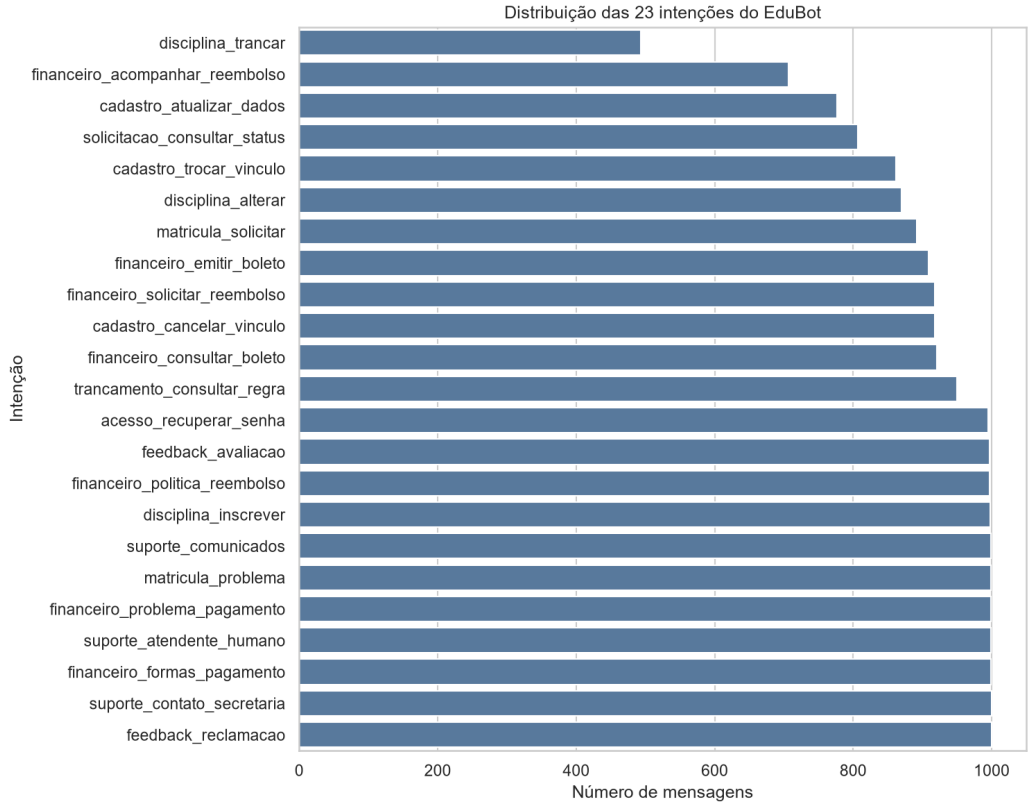


Figura 3 - Distribuição das 23 intenções

Intenção	Mensagens	Percentual
`acesso_recuperar_senha`	995	4,74%
`cadastro_atualizar_dados`	777	3,70%
`cadastro_cancelar_vinculo`	918	4,37%
`cadastro_trocar_vinculo`	862	4,10%
`disciplina_alterar`	870	4,14%
`disciplina_inscrever`	998	4,75%
`disciplina_trancar`	493	2,35%
`feedback_avaliacao`	997	4,75%
`feedback_reclamacao`	1.000	4,76%
`financeiro_acompanhar_reembolso`	707	3,37%
`financeiro_consultar_boleto`	921	4,38%
`financeiro_emitir_boleto`	909	4,33%
`financeiro_formas_pagamento`	999	4,76%
`financeiro_politica_reembolso`	997	4,75%
`financeiro_problema_pagamento`	999	4,76%
`financeiro_solicitar_reembolso`	918	4,37%

Intenção	Mensagens	Percentual
`matricula_problema`	999	4,76%
`matricula_solicitar`	892	4,25%
`solicitacao_consultar_status`	807	3,84%
`suporte_atendente_humano`	999	4,76%
`suporte_comunicados`	999	4,76%
`suporte_contato_secretaria`	1.000	4,76%
`trancamento_consultar_regra`	950	4,52%

As classes, descrições, quantidades, ambiguidades e limitações estão em `eda/pergunta_classificacao_tp3.md`.

2.4 Planejamento do T2

O baseline será TF-IDF com regressão logística. Depois, o mesmo conjunto de dados será usado para comparar `LinearSVC`. A avaliação terá Macro-F1 como métrica principal, além de precision, recall, acurácia e matriz de confusão.

O pipeline será treinado fora da API, salvo com uma versão e carregado uma vez na inicialização do FastAPI. O planejamento completo está em `eda/planejamento_t2.md`.

Item do pentest	Situação
Colega ou equipe adversária	A definir pelo professor após a entrega
URL ou IP da API alvo	A definir pelo professor após a entrega
Confirmação de acesso	Será registrada depois do pareamento

Na aula de 07/10/2026, o professor orientou que esses campos ficassem em aberto porque ele faria o pareamento depois das entregas. A mesma orientação foi confirmada nas aulas de 14/10/2026 e 21/10/2026.

3. Suíte de testes de segurança

A suíte de testes da API foi ampliada de 4 para **67 testes**, organizados por tema. Todos passam com `pytest tests/ -v`, localmente e no GitHub Actions.

Arquivo	Testes	O que cobre
`test_autenticacao.py`	12	Acesso sem token; token malformado, assinado com outra chave, com `alg: none`, expirado, sem `exp` e de usuário inexistente (todos 401); mesma resposta para senha errada e usuário inexistente; login e fluxo válidos
`test_bola.py`	5	Acesso à própria solicitação; bloqueio da solicitação de outro aluno; mesma resposta para "não existe" e "não é seu"; enumeração de IDs; dono definido pelo token, nunca pelo corpo
`test_validacao_entrada.py`	16	Campo extra, mensagem vazia, só espaços, acima de 2000 caracteres, tipos errados (422); erro 422 sem eco do valor enviado; SQL injection no ID, na mensagem e no login

Arquivo	Testes	O que cobre
`test_rate_limit.py`	13	429 na 6ª tentativa de login e no 21º `/predict`; `Retry-After`; bloqueio mesmo com a senha certa; `X-Forwarded-For` forjado não burla o limite; IP real atrás de proxy; um atacante bloqueado não afeta outro aluno
`test_headers_cors.py`	13	Headers de segurança em todas as respostas, inclusive 401, 404 e 429; `Cache-Control: no-store`; CSP, SRI e versão fixa do `/docs`; CORS
`test_documentacao.py`	8	Todas as rotas documentadas no OpenAPI com todas as respostas possíveis e schemas; esquema de autenticação; `/redoc` removido

```
tests/test_autenticacao.py::test_predict_sem_token_retorna_401 PASSED
tests/test_bola.py::test_acesso_a_solicitacao_de_outro_usuario_retorna_404 PASSED
tests/test_validacao_entrada.py::test_campo_extra_no_body_e_rejeitado PASSED
tests/test_rate_limit.py::test_login_retorna_429_apos_exceder_o_limite PASSED
tests/test_headers_cors.py::test_docs_tem_csp_propria_sem_unsafe_inline PASSED
...
============================== 67 passed ==============================
```

A saída completa está em `security/evidencias/pytest-tp3.txt`.

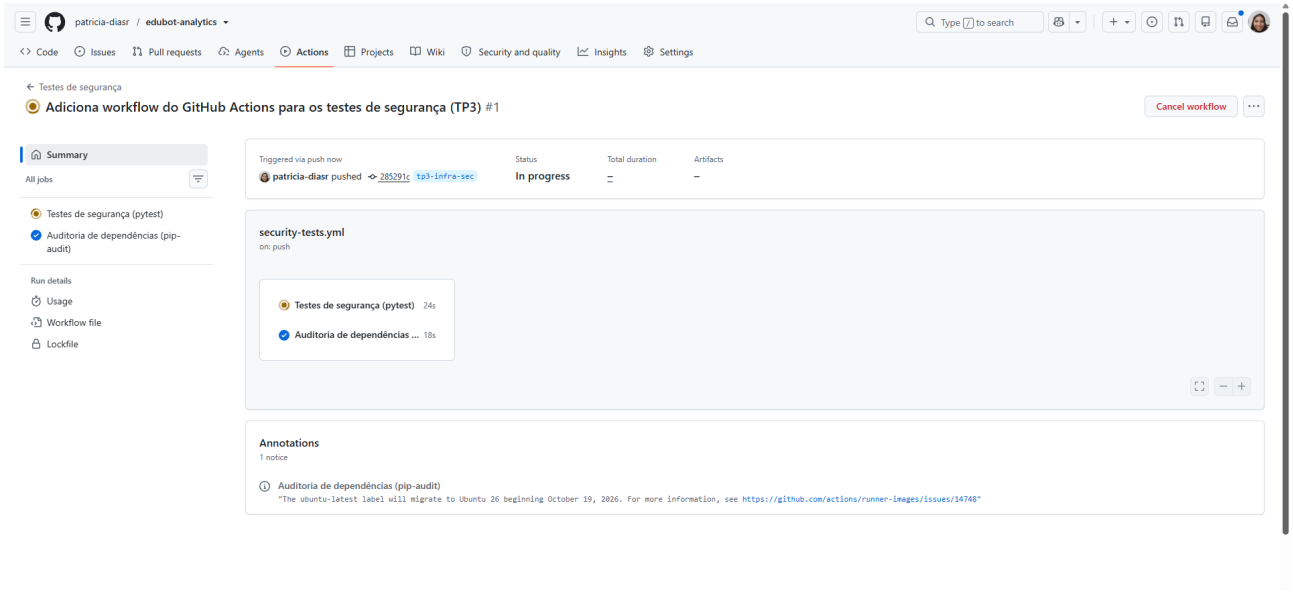
Os testes realmente detectam falhas: para confirmar que os testes não passam "sempre", a verificação de ownership foi removida de propósito. Os 3 testes de BOLA falharam imediatamente e voltaram a passar quando o código foi restaurado. A mesma demonstração foi feita no GitHub, com um pull request (seção 4).

4. Integração contínua com GitHub Actions

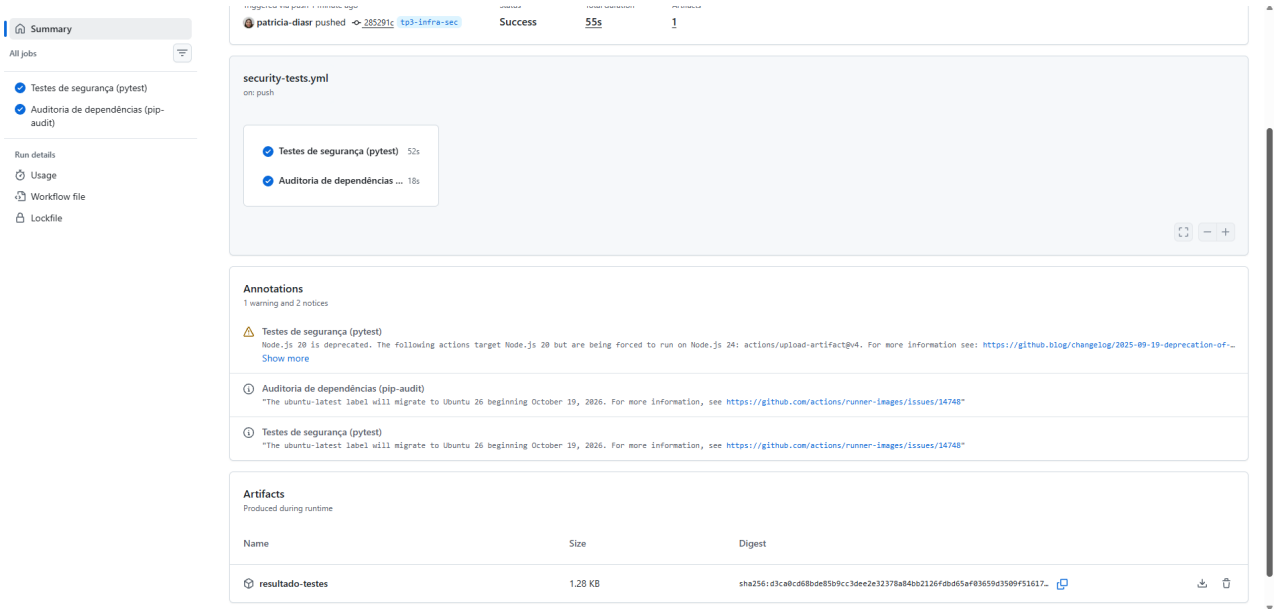
O workflow `.github/workflows/security-tests.yml` roda a cada push e em todo pull request para a `main`, com dois jobs:

1. **Testes de segurança (pytest):** instala as dependências e roda os 67 testes, com uma chave gerada só para aquela execução.
2. **Auditoria de dependências (pip-audit):** falha se alguma dependência tiver vulnerabilidade conhecida.

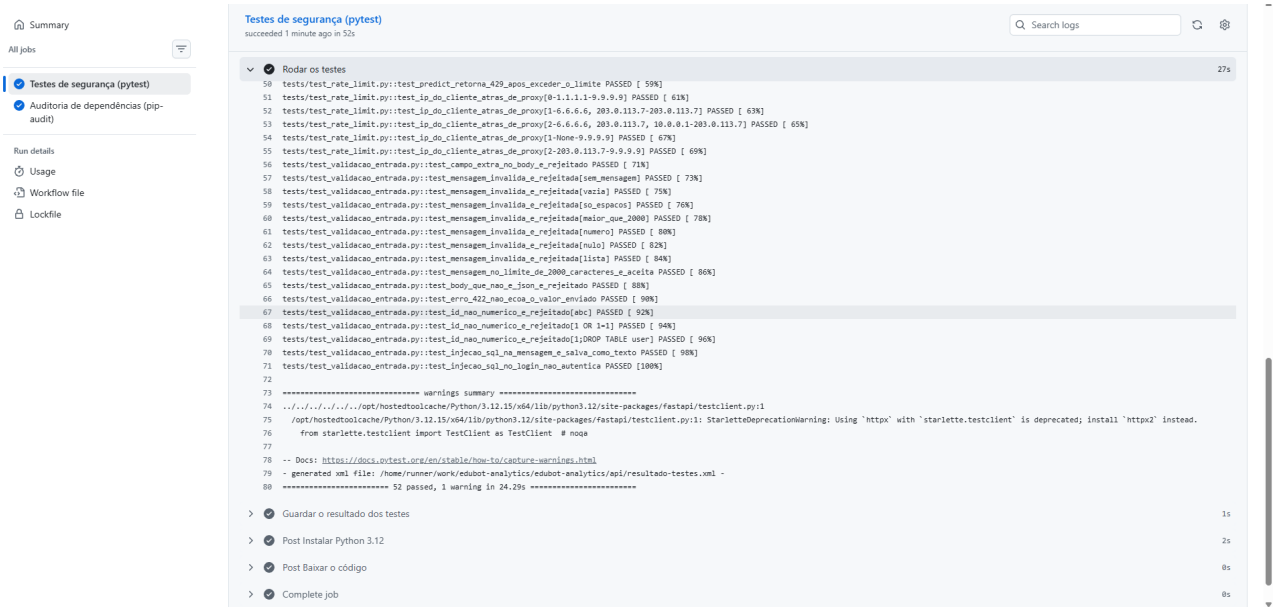
O workflow roda com permissão somente de leitura e não usa nenhum segredo real. Para que uma falha **impeça o merge**, a `main` é protegida por um ruleset: só recebe código por pull request, e com os dois checks aprovados. O Render, por sua vez, só publica uma nova versão depois que o CI aprova.



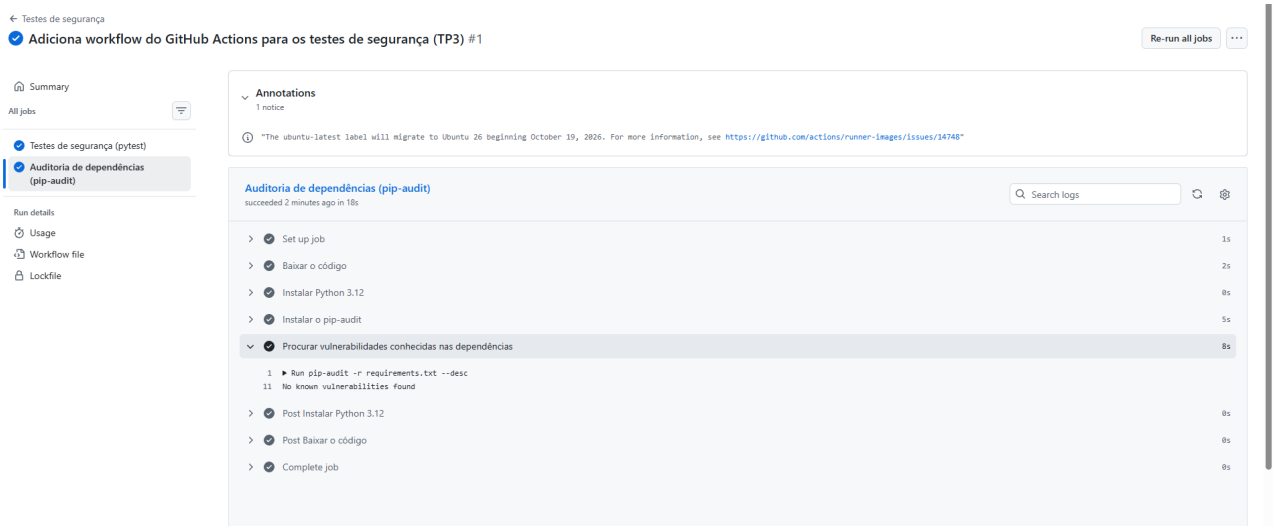
Print 01 - Workflow em execução no GitHub Actions



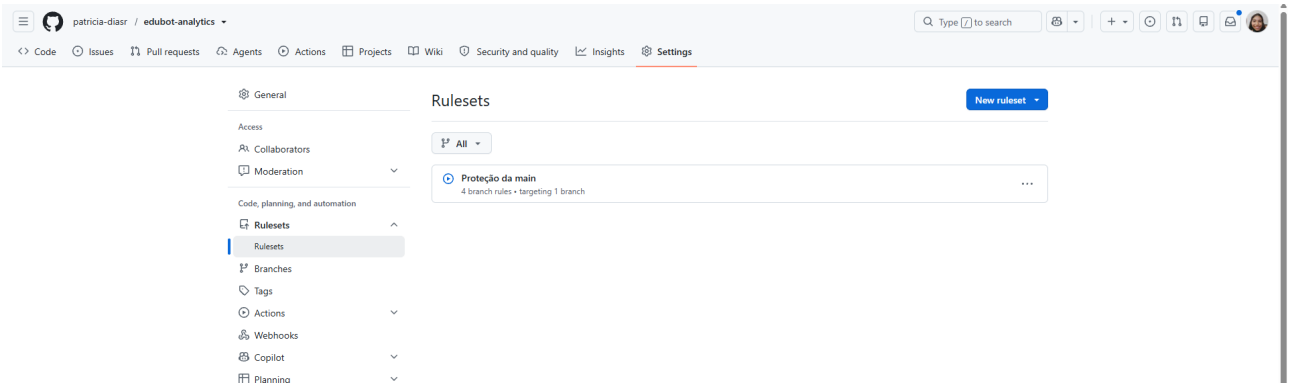
Print 02 - Execução concluída com os dois jobs aprovados



Print 03 - Job de testes com 52 testes aprovados (suíte na data do print; hoje são 67)

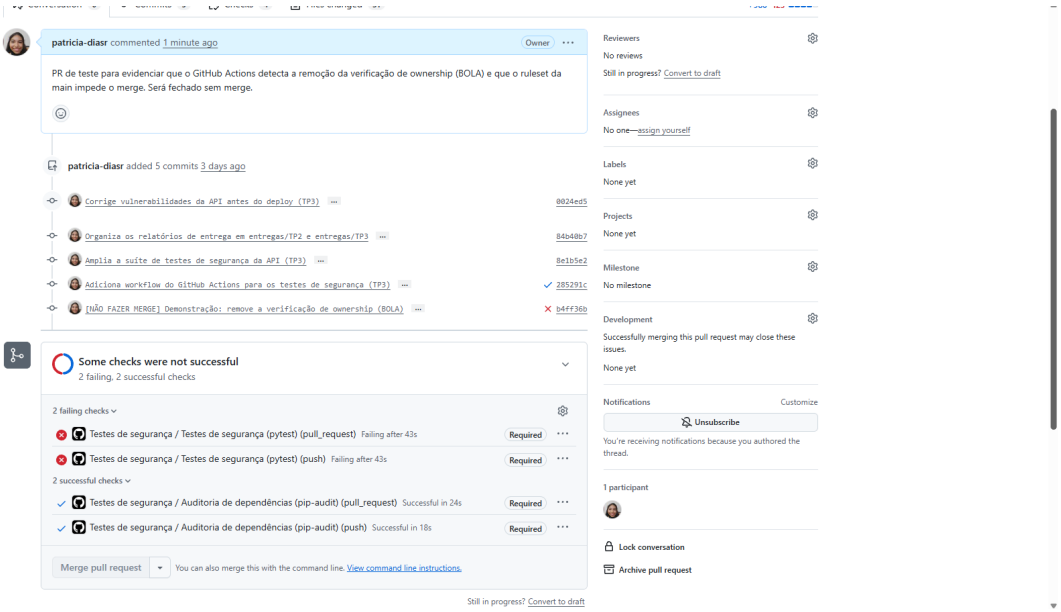


Print 04 - Job do pip-audit sem vulnerabilidades conhecidas

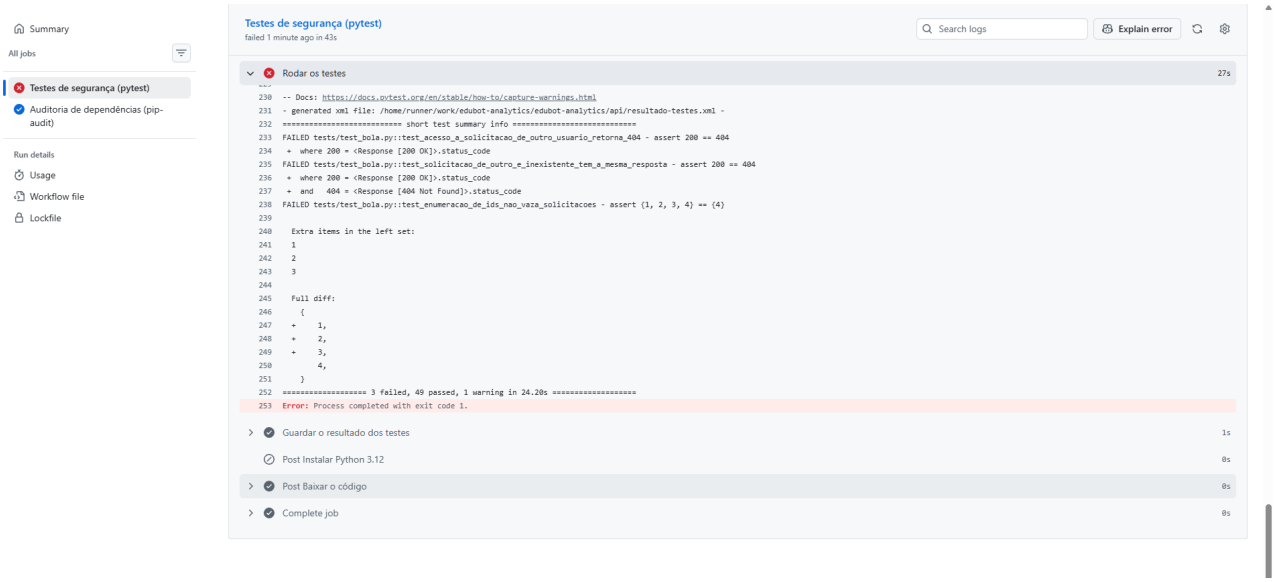


Print 05 - Ruleset da main exigindo pull request e os dois checks

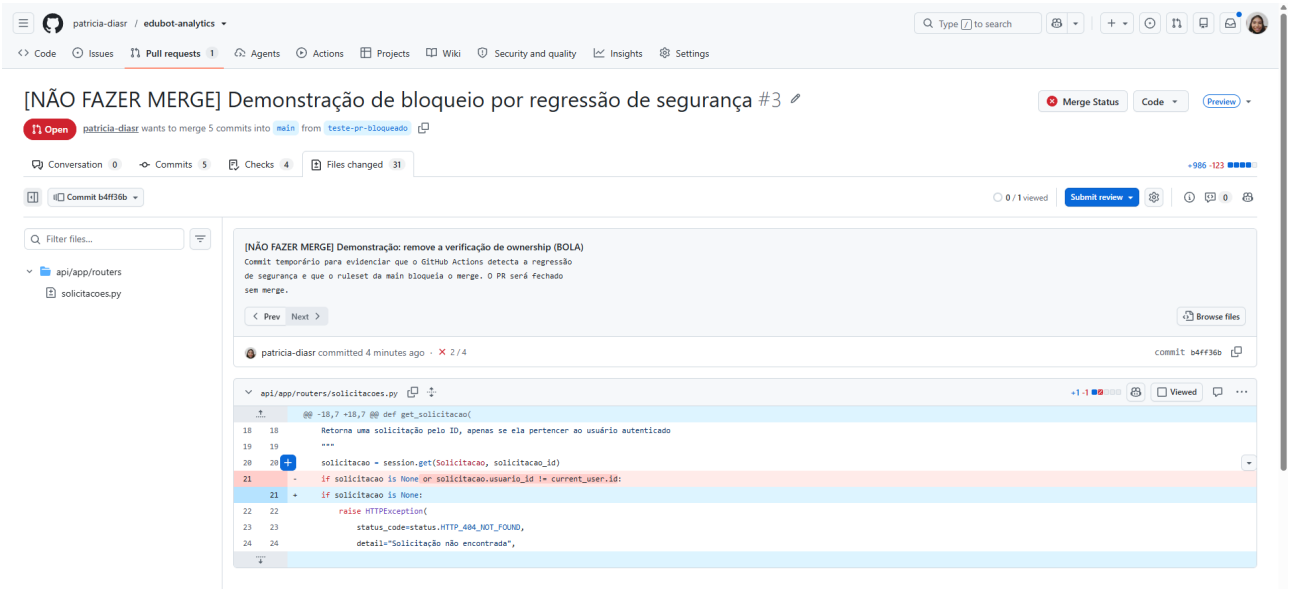
Demonstração do bloqueio: um pull request de teste removeu a verificação de ownership. Os testes de BOLA falharam no CI e o GitHub bloqueou o merge. O PR foi fechado sem merge.



Print 06 - Pull request com o check de testes falhando e o merge bloqueado



Print 07 - Job de testes mostrando os 3 testes de BOLA que falharam



Print 08 - Alteração do pull request de teste: remoção da verificação de dono

5. Auditoria final de segurança

A auditoria completa está em `security/auditoria-final-tp3.md`. A revisão do código do TP2, a auditoria de dependências e os testes contra a API publicada encontraram oito problemas, todos corrigidos:

ID	Achado	CVSS 3.1	Correção
A1	Chave do JWT com valor padrão no código público, permitindo forjar tokens	7.4 Alto	Chave obrigatória, forte, gerada no Render e fora do código
A2	35 vulnerabilidades conhecidas em 4 dependências	7.5 Alto	Dependências atualizadas, `python-jose` trocado por `PyJWT` e `passlib` por `bcrypt` (35 para 0)
A3	Rate limit ineficaz atrás do proxy do Render: todos os usuários dividiam o mesmo contador	7.5 Alto	IP do cliente lido do `cf-connecting-ip`, escrito pela Cloudflare
A4	Senhas dos usuários de teste no código público	6.5 Médio	Senhas em variáveis de ambiente
A5	`/predict` sem limite de requisições	4.3 Médio	20 requisições por minuto por IP
A6	Enumeração de usuários pelo tempo de resposta do login	3.7 Baixo	Tempo de resposta igual para usuário inexistente
A7	Erro 422 repetindo o valor enviado	Informativo	Handler próprio sem eco
A8	Mensagem só com espaços aceita	Informativo	Espaços removidos antes da validação

O achado A3 só apareceu em produção. Os testes locais passavam, mas, contra a URL pública, 7 logins errados seguidos não geravam 429. Os logs mostraram que a API enxergava o IP interno do balanceador do Render, e não o do cliente. Depois da correção, o teste online mostrou 401 nas 5 primeiras tentativas e 429 na 6ª, mesmo com `X-Forwarded-For` falso. Tentar forjar o próprio `cf-connecting-ip` é barrado pela Cloudflare (403).

5.1 Checklist OWASP API Security Top 10

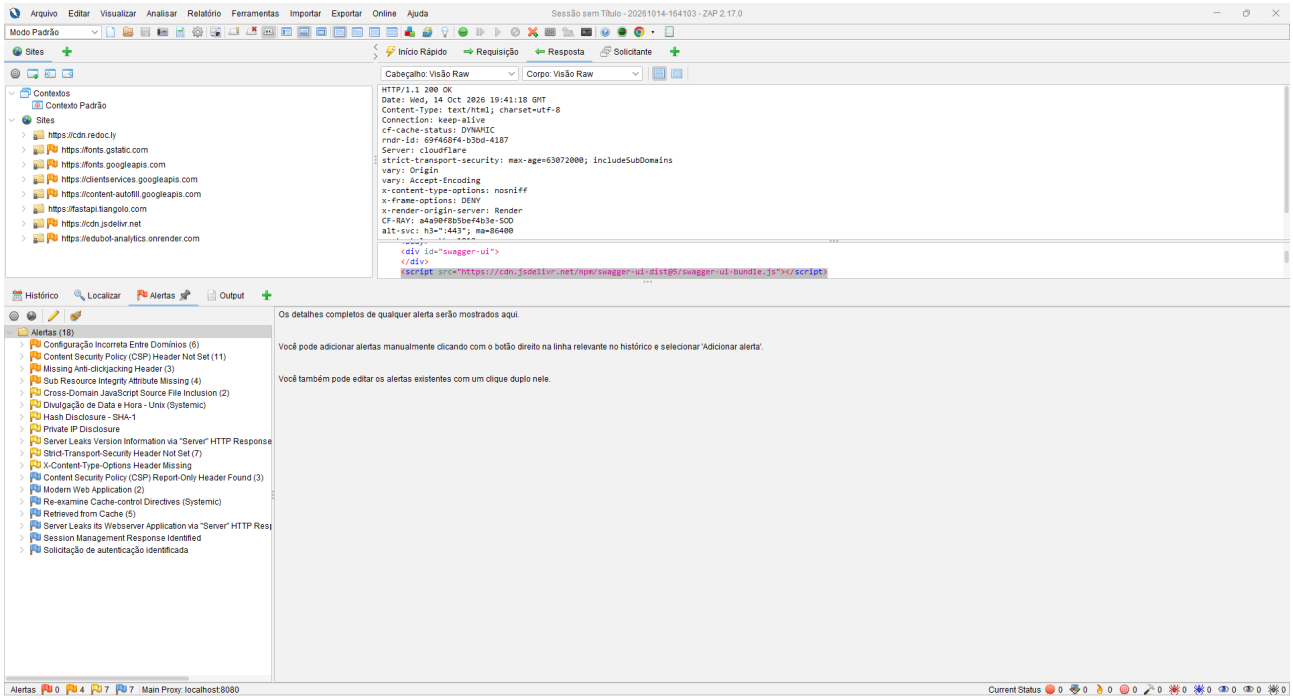
A auditoria traz o checklist do **OWASP API Security Top 10 (2023)**, com status e evidência de cada item, e os riscos aceitos com justificativa:

Risco OWASP	Status
API1 Broken Object Level Authorization	Resolvido
API2 Broken Authentication	Resolvido
API3 Broken Object Property Level Authorization	Resolvido
API4 Unrestricted Resource Consumption	Resolvido
API5 Broken Function Level Authorization	Não aplicável (sem funções privilegiadas)
API6 Unrestricted Access to Sensitive Business Flows	Resolvido
API7 Server Side Request Forgery	Não aplicável
API8 Security Misconfiguration	Resolvido
API9 Improper Inventory Management	Resolvido
API10 Unsafe Consumption of APIs	Reavaliar no TP4 (agente com LLM)

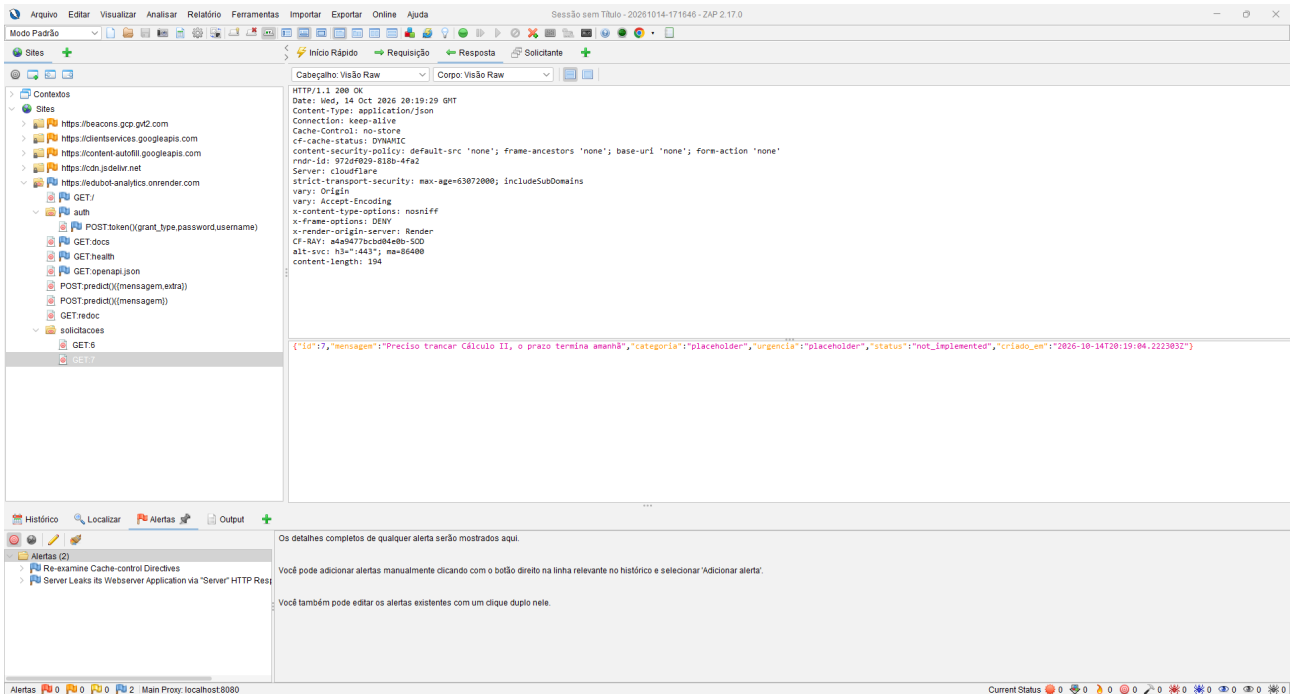
5.2 Scan final com OWASP ZAP

Um novo scan passivo foi feito contra a URL pública, com tráfego autenticado gerado pelo Swagger UI. Ele encontrou dois findings Médios na página `/docs`, que foram corrigidos: a página passou a ter CSP própria sem `'unsafe-inline'`, o Swagger UI passou a ter versão fixa e SRI, e o `/redoc` foi removido. O scan de verificação confirmou o resultado.

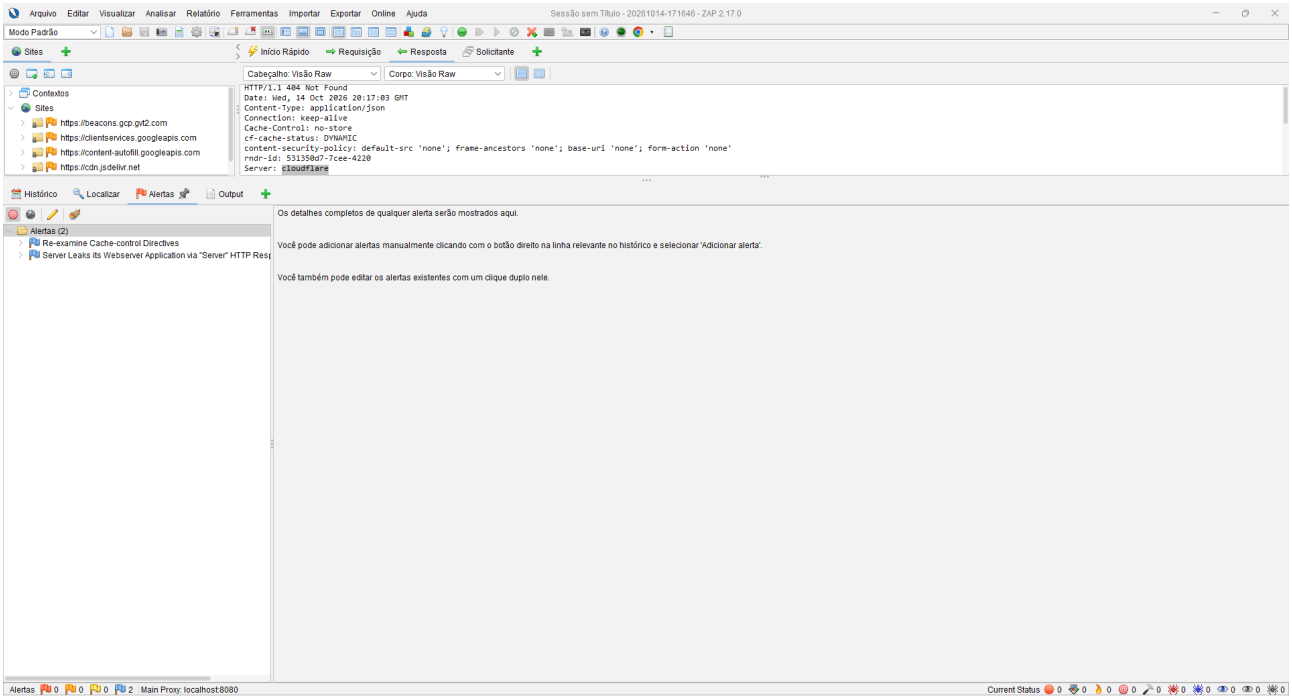
Risco	Scan inicial	Scan de verificação
Alto	0	0
Médio	2	**0**
Baixo	1	**0**
Informativo	5	5 (aceitos, sem impacto)



Print 13 - Scan ZAP inicial: alertas da sessão (inclui domínios de terceiros visitados pelo navegador)



Print 14 - Scan de verificação: rotas exploradas e alertas em escopo, apenas informativos

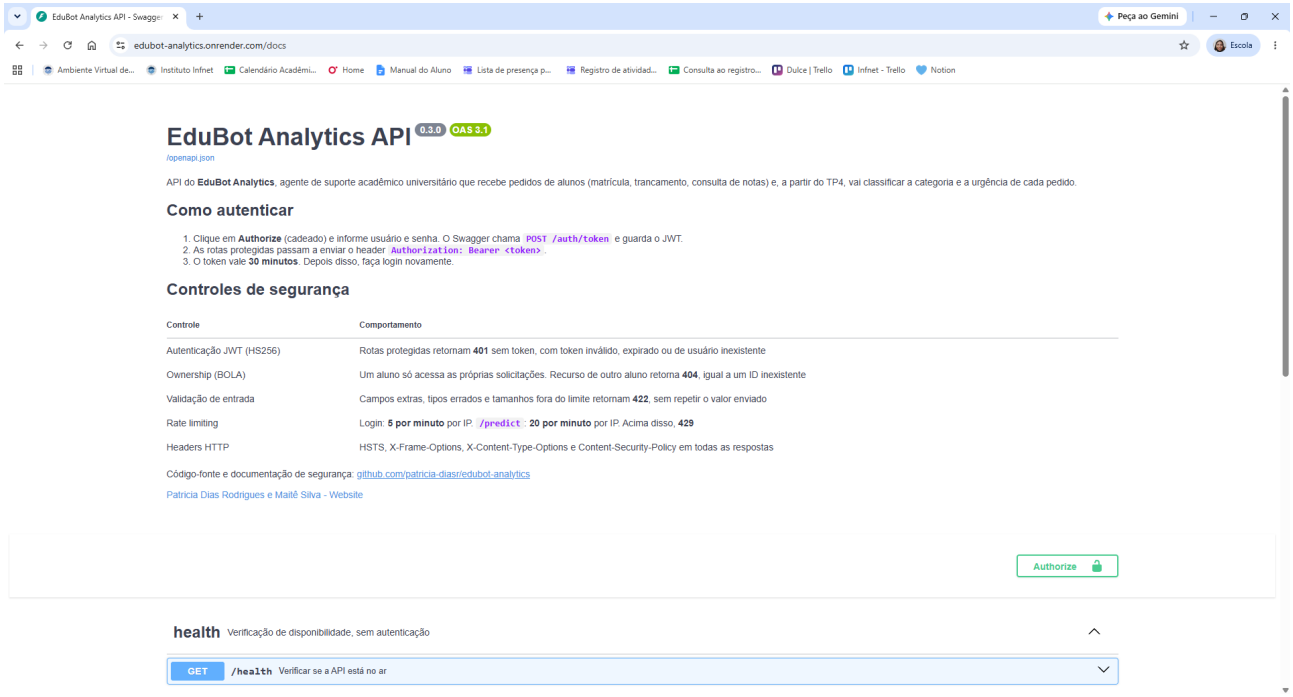


Print 15 - Scan de verificação: /redoc removido (404), com os headers de segurança

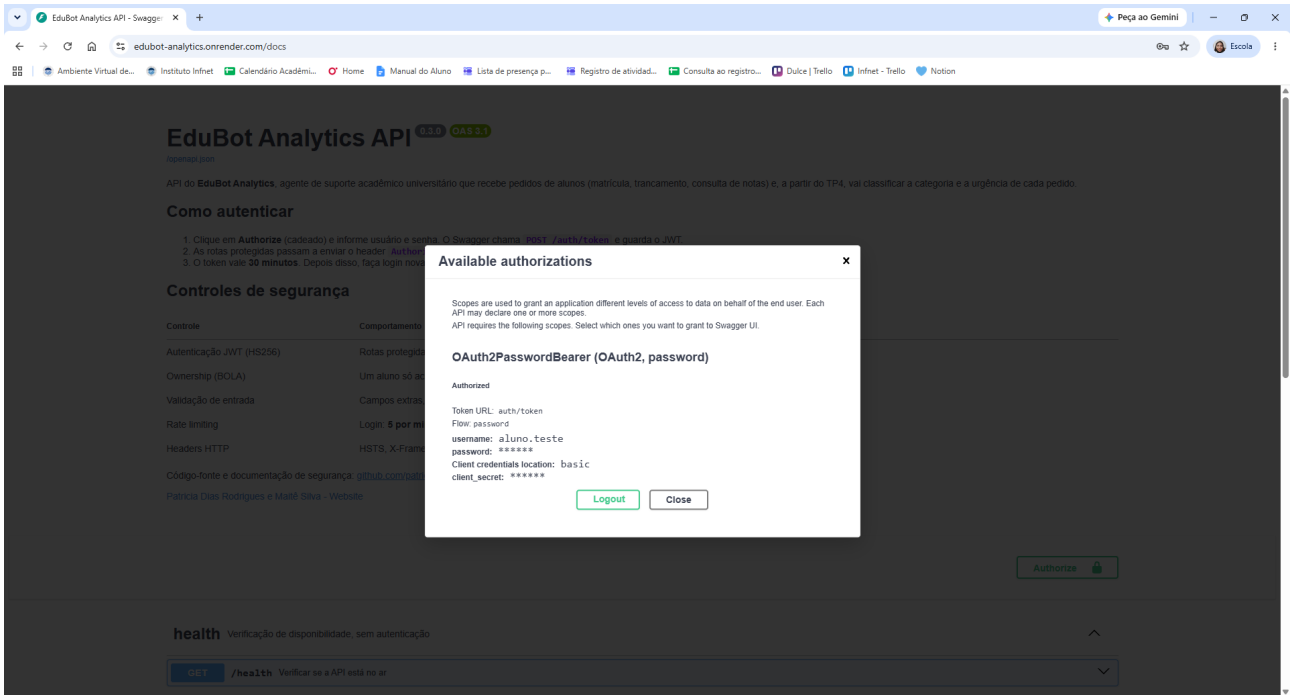
Os findings estão detalhados em `security/zap-findings-tp3.md`, e os relatórios em `security/zap-report-tp3-inicial.html` e `security/zap-report-tp3-verificacao.html`. **Não há nenhum finding Alto, Médio ou Baixo pendente.**

6. Documentação OpenAPI (/docs)

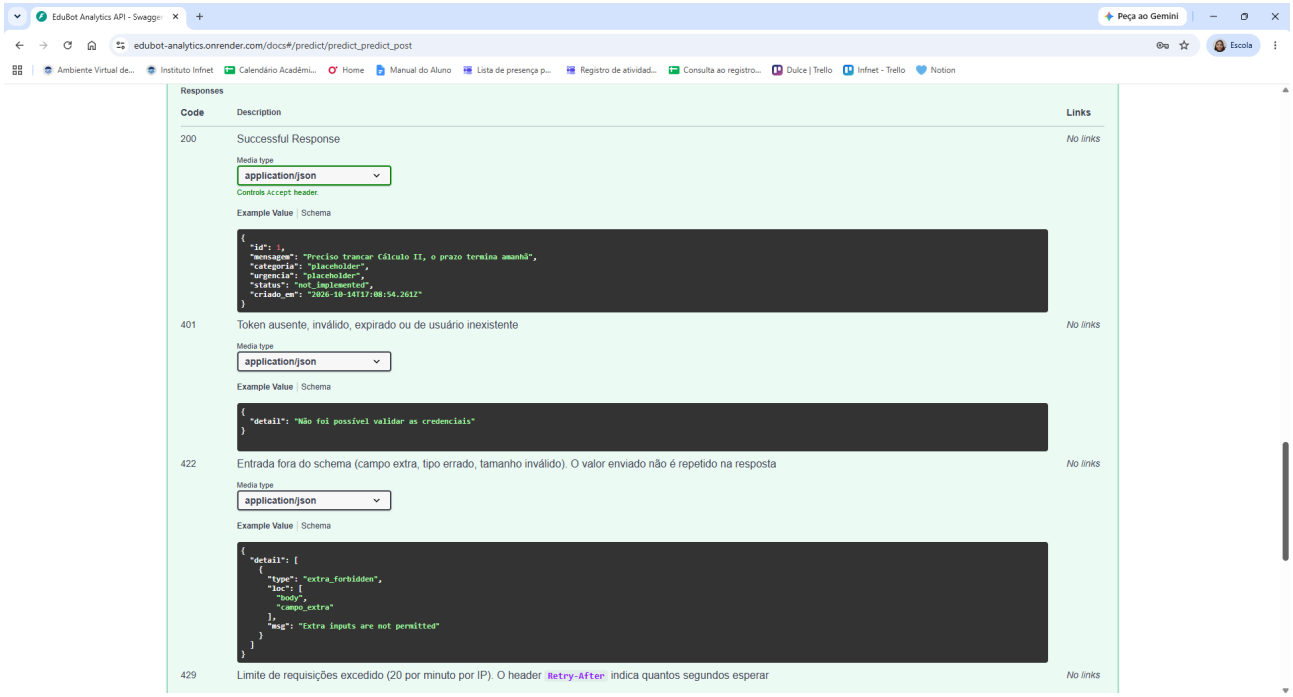
A especificação OpenAPI está em /docs e documenta todas as rotas com resumo, descrição, schemas de entrada e saída, exemplos e **todas as respostas possíveis** (200, 401, 404, 422 e 429). A página abre com um guia de autenticação e uma tabela dos controles de segurança. Um teste automatizado garante que nenhuma rota fique sem documentação.



Print 09 - Página /docs com o guia de autenticação e os controles de segurança



Print 10 - Login pelo botão Authorize do Swagger



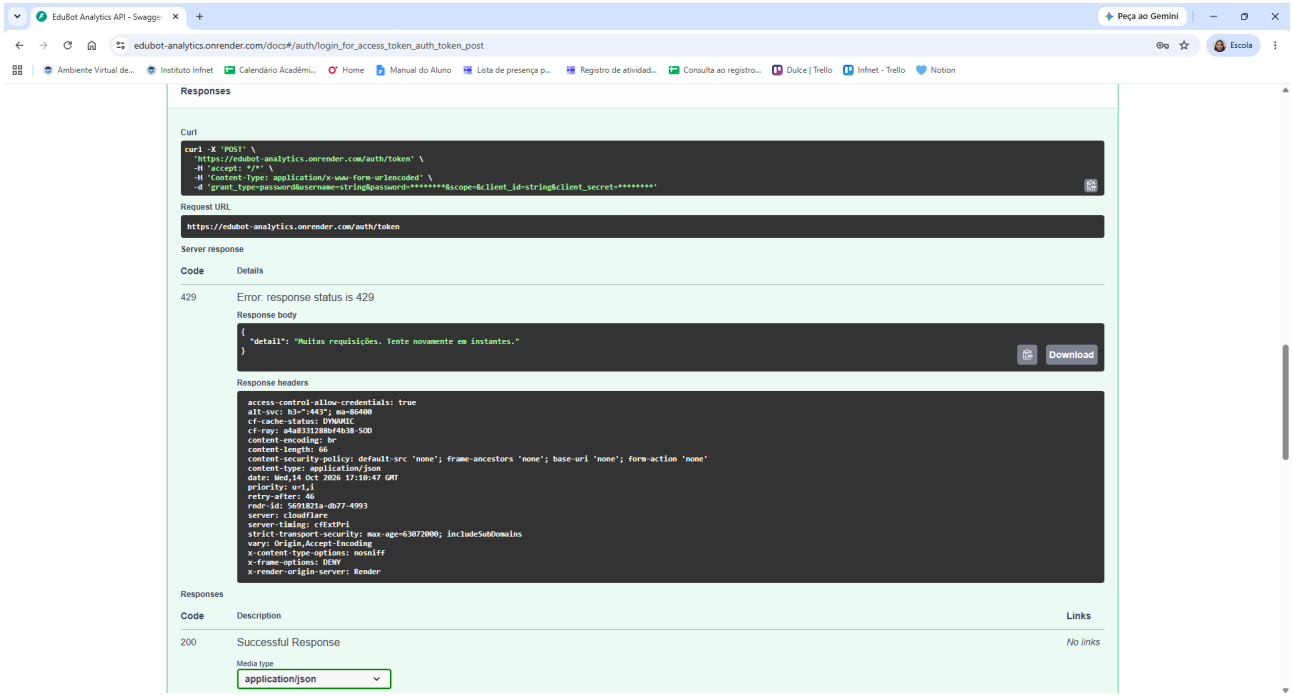
Print 11 - POST /predict com as respostas documentadas

7. Deploy e prontidão para o pentest

A API está publicada no Render (plano gratuito), em https://edubot-analytics.onrender.com. A configuração completa está em `security/deploy-render.md`:

- HTTPS terminado pela Cloudflare/Render, com redirecionamento de HTTP e HSTS efetivo (o risco aceito no TP2 foi resolvido);
- `SECRET_KEY` gerada pelo Render e senhas de teste apenas nas variáveis de ambiente;
- Python 3.12, a mesma versão do CI;
- deploy automático somente depois que o GitHub Actions aprova.

Requisito para o pentest	Situação
API rodando sem erros em URL pública	Atendido (`/health` 200)
Autenticação funcionando	Atendido (print 10)
Dados de teste disponíveis	3 alunos, cada um com solicitações próprias, recriados a cada inicialização
Documentação acessível	Atendido (prints 09 a 11)
Nenhum finding Médio ou Alto pendente	Atendido (seção 5.2)



Print 12 - Rate limit na API publicada: 429 com Retry-After e todos os headers de segurança

8. Planejamento do T2: pentest e segurança do agente

Item	Situação
Colega adversário	A definir pelo professor após a entrega do TP3
URL ou IP da API adversária	A definir pelo professor após a entrega do TP3
Período do pentest	A definir pelo professor
Plano de escopo do pentest	Concluído (`security/plano-pentest.md`)
Plano de segurança do agente	Concluído (`security/plano-pentest.md`)

8.1 Plano de escopo do pentest

Pentest que a dupla vai realizar (TP4): o plano define as regras de engajamento (somente a URL informada, dentro do período, com as contas de teste fornecidas; sem negação de serviço; sem ataques à plataforma de hospedagem), as etapas (reconhecimento, análise de configuração, testes de controles de acesso e de entrada, testes do agente e relatório), tendo como referência o OWASP WSTG e o OWASP API Security Top 10, e o formato de cada achado: categoria, evidência, impacto, severidade CVSS 3.1 e recomendação.

Escopo para a dupla que vai testar o EduBot: URL, documentação e repositório; no escopo, todas as rotas e, no TP4, o agente; fora do escopo, negação de serviço, a infraestrutura do Render e da Cloudflare, as contas da dupla e engenharia social. As senhas das contas de teste não ficam no repositório e serão enviadas por e-mail à dupla adversária. Contatos para credenciais e suporte: Patricia Dias Rodrigues (patricia.rodrigues@al.infnet.edu.br) e Maitê Mota Belo de Souza Silva (maite.silva@al.infnet.edu.br).

8.2 Plano de segurança do agente

No TP4, o `/predict` vai usar um agente com memória e ferramentas. Para responder ao desafio de segurança do EduBot, os controles planejados são:

- **Ferramentas somente de leitura:** o agente não terá nenhuma ferramenta capaz de alterar notas, matrículas ou cadastros.
- **Identidade definida pelo servidor:** o aluno é identificado pelo token JWT; as ferramentas recebem o ID do aluno da API, nunca do texto digitado na conversa.
- **Mesma regra de ownership da API** nas ferramentas de consulta.
- **Memória separada por aluno.**
- **Validação da saída:** categoria e urgência conferidas contra a lista de valores permitidos.
- **Chave do modelo de linguagem** apenas em variável de ambiente no Render.
- **Rate limit e limite de tamanho** do `/predict` mantidos, para controlar o custo.
- **Testes de segurança do agente** na mesma suíte do CI.

9. Atualização da modelagem de ameaças

Com a API publicada, o DFD, a análise CIA e a modelagem de ameaças dos TPs anteriores foram atualizados.

DFD versão 3 (`dfd/dfd.md`), dividido em dois diagramas e com quatro trust boundaries: (1) Internet e borda da plataforma, (2) borda e aplicação, onde só o `cf-connecting-ip` é confiável, (3) aplicação e dados (banco, segredos e logs) e (4) cadeia de entrega.

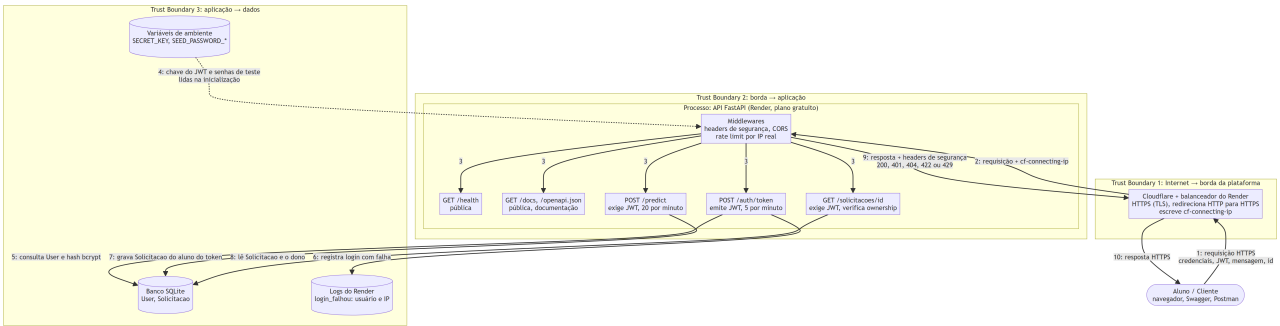


Figura 4 - DFD v3: fluxo de uma requisição

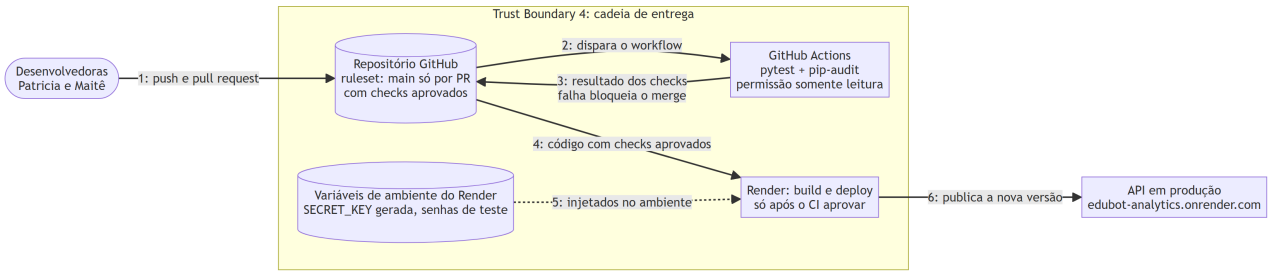


Figura 5 - DFD v3: cadeia de entrega (CI/CD)

Versão do DFD	TP	Principais elementos
1	TP1	3 rotas, credenciais em memória (`fake_db.py`), 2 trust boundaries
2	TP2	SQLite, rota `GET /solicitacoes/{id}` com ownership, rate limit no login
3	TP3	Borda Cloudflare/Render com HTTPS, segredos, logs, documentação, CI/CD; 4 trust boundaries

Análise CIA (`dfd/analise-cia.md`), estendida de 5 para 10 componentes:

Componente	Confidencialidade	Integridade	Disponibilidade
GET /health	Baixa	Baixa	Alta
POST /auth/token	Alta	Alta	Alta
POST /predict	Alta	Alta	Média
GET /solicitacoes/{id}	Alta	Alta	Média
Banco de dados (SQLite)	Altíssima	Alta	Baixa
Borda (Cloudflare + Render)	Alta	Alta	Média
Documentação (/docs, /openapi.json)	Baixa	Média	Baixa
Variáveis de ambiente (segredos)	Altíssima	Alta	Alta
Logs de segurança	Média	Média	Baixa
Cadeia de entrega (CI/CD)	Média	Altíssima	Média

A disponibilidade do banco caiu de média para baixa no TP3, porque o disco do plano gratuito do Render é apagado a cada deploy. É um risco aceito: os dados de teste são recriados automaticamente.

Modelagem de ameaças STRIDE (`dfd/threat-model-stride.md`), criada no TP3 para completar a modelagem de ameaças iniciada no TP1: 32 ameaças, cada uma ligada a um elemento do DFD, com o controle, o status e o teste que a comprova. Inclui as ameaças do agente de IA, como prompt injection para alterar notas ou acessar dados de outros alunos.

Categoria	Mitigadas	Aceitas	Planejadas (agente)
Spoofing	4	1	0
Tampering	6	0	1
Repudiation	1	1	0
Information disclosure	6	1	2
Denial of service	4	1	1

Categoria	Mitigadas	Aceitas	Planejadas (agente)
Elevation of privilege	1	0	2
Total	**22**	**4**	**6**

10. Uso de IA

Conforme a política de Sinal Verde da disciplina:

- Na frente de Dados/IA, foram usados o Claude e o Cursor para triagem de datasets, estrutura dos notebooks, scripts e revisão de texto. A escolha do dataset, o mapeamento, a limpeza, as hipóteses e as interpretações são decisões da aluna responsável.
- Na frente de Infra/Sec, o Claude foi usado como apoio na implementação e revisão da API, na auditoria de segurança e na revisão da documentação. As decisões de implementação, a revisão do código e a validação das soluções foram feitas pela aluna responsável.
- Os números, testes e relatórios citados vêm da execução das ferramentas indicadas e podem ser reproduzidos a partir do repositório.

11. Índice de evidências

Evidência	Local
Notebook de regressão e figuras	`eda/eda_edubot_tp3.ipynb`, `eda/figures/fig10` a `fig12`
Pergunta de classificação	`eda/pergunta_classificacao_tp3.md`
Planejamento técnico do T2	`eda/planejamento_t2.md`
Código da API	`api/app/`
Testes de segurança e saída do pytest	`api/tests/`, `security/evidencias/pytest-tp3.txt`
Auditoria de dependências (antes e depois)	`security/evidencias/pip-audit-antes-tp2.txt`, `pip-audit-depois-tp3.txt`
Workflow de CI	`.github/workflows/security-tests.yml`
DFD, CIA e STRIDE	`dfd/dfd.md`, `dfd/analise-cia.md`, `dfd/threat-model-stride.md`
Relatórios e findings do ZAP	`security/zap-report-tp3-*.html`, `security/zap-findings-tp3.md`
Auditoria final e checklist OWASP	`security/auditoria-final-tp3.md`
Decisões técnicas	`security/decisoes-tecnicas.md`
Deploy	`security/deploy-render.md`
Plano de pentest e segurança do agente	`security/plano-pentest.md`
Prints	`entregas/TP3/prints/`